

# Una plataforma interactiva para el Análisis y Visualización de patrones Espacio-Temporales: Un caso de Estudio de delitos graves en la Ciudad de Nueva York

1<sup>st</sup> Luz Marina Pilco Pancca

*Ciencia de la computación*

*Universidad Nacional de San Agustín*

Arequipa, Perú

lpilco@unsa.edu.pe

2<sup>nd</sup> Junior Valentin Gomez contreras

*Ciencia de la computación*

*Universidad Nacional de San Agustín*

Arequipa, Perú

jgomezcon@unsa.edu.pe

3<sup>rd</sup> Erika Sejje Condori

*Ciencia de la computación*

*Universidad Nacional de San Agustín*

Arequipa, Perú

esejjec@unsa.edu.pe

**Abstract**—Con el avance tecnológico se generan millones de datos, la extracción de conocimiento de estos datos se ha convertido en un desafío. Los delitos y la criminalidad se encuentran ampliamente distribuidos en diversas partes del mundo, el problema del crimen en cualquier ciudad, incluida Nueva York, es multifacético e impacta directamente la calidad de vida de sus habitantes. Se presenta una plataforma web interactiva diseñada para el análisis y visualización de patrones espacio-temporales en datos de delitos graves en la Ciudad de Nueva York desde el año 2018 a 2023. La plataforma integra técnicas avanzadas de visualización de datos con métodos estadísticos para identificar y analizar tendencias en la criminalidad, permitiendo a los usuarios visualizar por año, tipo de crimen, municipios, características del sospechoso y la víctima como sus rango de edades, raza, sexo; como también identificar puntos críticos (hotspots). Asimismo, la plataforma web permite al usuario realizar un análisis de similitud, correlación, de tendencias y anomalías. Se utilizó Streamlit para crear una interfaz interactiva y amigable para el usuario, PySpark para el procesamiento y análisis de grandes volúmenes de datos espacio-temporales, Dashboards personalizados para la visualización de datos y la interpretación de resultados.

**Index Terms**—Crimen, espacio-temporales, delitos graves, plataforma Web, Streamlit, PySpark, Dashboards, hotspots.

## I. INTRODUCCIÓN

El avance tecnológico ha transformado de manera radical la forma en que se recopila, almacena y analiza la información. Actualmente se generan millones de datos espacio-temporales, y junto a ello la capacidad de capturar datos en tiempo real y a gran escala se ha convertido en un desafío [1]. La extracción de conocimiento de estos datos se ha convertido en tema de investigación. Los delitos y la criminalidad se encuentran ampliamente distribuidos en diversas comunidades a nivel mundial [2], al punto de que no existe ninguna comunidad que esté completamente libre de algún acto delictivo. El problema del crimen en cualquier ciudad, incluida Nueva York, es multifacético y impacta directamente la calidad de vida de sus habitantes. La creciente incidencia de crímenes violentos y contra la propiedad plantea desafíos significativos para las

autoridades locales y la comunidad en general, afectando la seguridad personal, la estabilidad económica y el bienestar psicológico de los residentes.

Es crucial realizar un estudio profundo y sistemático sobre la criminalidad para entender mejor los factores subyacentes que la perpetúan y para desarrollar estrategias efectivas de prevención y respuesta. En este estudio se realizará un análisis y visualización de patrones Espacio-Temporales de delitos graves en la Ciudad de Nueva York. El visualización y análisis de la delincuencia ayuda a tomar decisiones, como las intervenciones policiales, aumentar las patrullas policiales en las áreas críticas puede reducir de manera efectiva el número de delitos.

La extracción y el análisis de patrones delictivos en las grandes ciudades es un problema espacio-temporal complejo. La dificultad del problema está vinculada a dos factores principales: la naturaleza dispersa de la actividad delictiva y su propagación en grandes áreas espaciales [3]. El reconocimiento de patrones se ha considerado durante mucho tiempo como un factor crucial en la prevención y reducción del delito [4], la visualización de diferentes patrones ocultos en los datos de series temporales delictivas es otro problema en este contexto, principalmente debido a la cantidad de patrones que pueden aparecer en el análisis de series temporales. Se han desarrollado varios enfoques de minería de datos y aprendizaje automático, sin obtener buenos resultados en el mundo real, recientemente los investigadores han explorado el área de análisis de series temporales para la predicción del delito, se obtuvieron resultados más eficientes [5].

## II. TRABAJOS RELACIONADOS

Se han desarrollado varios enfoques de minería de datos y aprendizaje automático, pero no han funcionado en el mundo real, recientemente los investigadores han explorado el área de análisis de series temporales para la predicción del delito y han descubierto que es eficiente [5]. Botsarakos [6] analizan diversos modelos de aprendizaje profundo, como

LSTM (Long Short-Term Memory), CLSTM (Convolutional LSTM), 3DCNN (Redes Neuronales Convolucionales en Tres Dimensiones) y GCNN (Graph CNN), con el fin de determinar cuál de ellos tiene una mayor precisión y captura de manera más efectiva las correlaciones espaciales y temporales de los patrones delictivos. CLSTM logró capturar mejor las correlaciones espacio-temporales entre los datos históricos de delitos, CLSTM es una combinación de las características de los modelos de redes neuronales convolucionales (CNN) y los modelos de aprendizaje profundo de memoria a largo plazo (LM).

Butt [5] realizó una revisión sistemática de detección y predicción de puntos críticos de delincuencia espacio-temporales, los autores no lograron realizar un estudio exhaustivo, sin embargo analizaron críticamente la literatura existente, se desprende claramente que DBSCAN y Random forest resultan útiles y eficientes en términos de precisión y rendimiento, pero presenta limitaciones, mientras que las series temporales para la predicción del delito es eficiente. Ying [4] analizó los datos de delitos graves de la ciudad de Nueva York en los últimos 5 años (2015-2020) y descubrió patrones de puntos críticos delictivos y patrones temporales, para identificar puntos críticos y demostrar sus asociaciones con características espaciales se utilizó algoritmos de agrupamiento basados en densidad, mapeo temático de cuadrícula y mapa de calor de densidad. Además, Ying realizó una visualización en 3D que mejoró la identificación del desplazamiento de los puntos conflictivos a lo largo del tiempo.

Los métodos de co-agrupamiento posibilitan el análisis simultáneo de patrones espaciales y temporales mediante la identificación de agrupaciones tanto de ubicaciones como de marcas de tiempo. Al integrar el co-agrupamiento con vistas múltiples coordinadas (CMV) en una plataforma interactiva de análisis geovisual, se mejora el proceso de exploración de datos espacio-temporales y de interpretación de sus resultados. Xiaojing [7] presentan una plataforma de análisis geovisual interactiva basada en la web para el análisis exploratorio de coagrupación de datos espaciotemporales, esta plataforma permite a los usuarios cargar datos y explorarlos utilizando vistas múltiples coordinadas interactivas (CMV), permite elegir parámetros e implementar el algoritmo de co-agrupamiento, y explorar los resultados del co-agrupamiento, además permite la exploración de patrones espacio-temporales concurrentes a partir de grandes cantidades de datos espacio-temporales. Ajagbe [2] llevó a cabo un estudio con el propósito de monitorear el cinturón delictivo mediante la visualización de datos, utilizando la herramienta Folium, que permite superponer datos de texto sobre un mapa de Chloroplet. Ajagbe propuso un algoritmo para la visualización de los ataques de la milicia étnica Fulani en Nigeria y aprovechó la herramienta de visualización de datos llamada Folium como una herramienta de visualización de datos.

Se presentaron diferentes herramientas, plataformas, algoritmos y técnicas para visualizar, analizar los patrones delictivos. Kaif [8] presenta una plataforma de análisis geovisual interactiva basada en la web para analizar datos sobre delitos,

integra principios de criminología espacial y técnicas de SIG (Sistema de información geográfica), su arquitectura incorpora React, JavaScript, Bootstrap, Express, GeoServer, Node.js, QGIS y OpenLayers, la plataforma ofrece un panel principal con información estadística presentada a través de gráficos de anillos y de líneas, junto con un mapa interactivo para una exploración detallada. Anuar [9] aplica el mapeo del delito para identificar los puntos críticos delictivos en Malasia, la visualización de datos se realizó mediante herramientas SIG (Sistema de Información Geográfica), se utilizó Tableau para obtener más información sobre los patrones y comportamientos de los datos de delitos violentos.

Catlett [10] presenta un enfoque predictivo que utiliza el análisis espacial y modelos autorregresivos para detectar automáticamente zonas de alto riesgo delictivo en áreas urbanas y prever de manera confiable las tendencias de criminalidad en cada una de esas regiones. Catlett presentó un algoritmo general para la predicción de delitos espacio-temporales en zonas urbanas, aplicado en el contexto de dividir grandes áreas de ciudades en subáreas mediante la identificación de regiones con alta densidad poblacional. Castro [11] presenta el proyecto SIM4SECURITY que tiene como objetivo construir una solución tecnológica para apoyar la toma de decisiones en materia de seguridad de esta manera optimizar la distribución de las fuerzas policiales. SIM4SECURITY se basa en un modelo SIG y en la implementación de escenarios demográficos, se adoptó un enfoque de visualización de datos y narración mediante la creación de cuadros de mando, junto con el desarrollo de escenarios demográficos y delictivos. García [3] presenta una herramienta analítica llamada CriPAV (Análisis y visualización de patrones delictivos), una nueva metodología para abordar los problemas de extracción, visualización de diferentes patrones ocultos y análisis de patrones delictivos en grandes ciudades, su metodología permite el análisis de patrones delictivos espacio-temporales a detalle, su enfoque se compone de dos componentes principales; el primer componente se basa en un mecanismo estocástico, y el segundo componente se basa en un mecanismo de aprendizaje profundo para incorporar series temporales de delitos en el espacio cartesiano. CriPAV permite una vista global y a nivel de calle, vía los patrones delictivos, además permite identificar ubicaciones espaciales donde las series temporales de delitos tienen un comportamiento similar.

### III. MARCO TEÓRICO

Esta sección presenta los fundamentos teóricos que sustentan el desarrollo de la plataforma interactiva para el análisis y visualización de patrones espacio-temporales, con un enfoque en delitos graves en la ciudad de Nueva York. Se abordan conceptos clave en el análisis de datos criminales, la identificación de patrones y la utilización de herramientas geovisuales para apoyar la toma de decisiones.

#### A. Análisis exploratorio de datos

El análisis exploratorio de datos (AED) es un paso crucial en el estudio de patrones criminales. Consiste en examinar

de manera preliminar los datos disponibles para identificar tendencias, anomalías y relaciones subyacentes [12]. El AED utiliza diversas técnicas, como la visualización de datos, distribución de datos, relación entre características el uso de estadísticas descriptivas, y la aplicación de métodos de agrupamiento para descubrir insights iniciales sobre la distribución de los delitos [13]. Sometemos a un análisis exploratorio de datos (EDA) con el fin de responder preguntas sobre qué, dónde y cuándo ocurren los delitos.

#### B. Análisis de Patrones Criminales

El análisis de patrones criminales es una disciplina fundamental en criminología que busca identificar y comprender las regularidades en la ocurrencia de delitos. Sustancialmente, el análisis de patrones criminales se centra en identificar y comprender las regularidades en los datos de delitos, tanto en términos de ubicación como de tiempo [14]. Este análisis permite predecir comportamientos futuros y diseñar estrategias de prevención más efectivas [15]. Nos enfocaremos en detectar patrones recurrentes en términos de ubicación, tiempo, tipo de delito y edad, esto nos permite no solo entender el comportamiento delictivo, sino también predecir futuros incidentes y diseñar estrategias de prevención más efectivas.

1) *Patrones Criminales:* Se discuten los diferentes tipos de patrones criminales, incluyendo patrones espacio-temporales recurrentes, comportamientos de desplazamiento de delitos y la identificación de tendencias en diferentes períodos [16]. Estos patrones pueden variar según factores como la hora del día, la ubicación, y el tipo de crimen [17]. Los Patrones Espaciales se refieren a la distribución geográfica de los delitos. Identificar "hotspots" o áreas de alta incidencia delictiva es un componente clave en este tipo de análisis. En los Patrones Temporales los delitos no ocurren de manera aleatoria en el tiempo, por el contrario muchos crímenes muestran una clara dependencia temporal, con variaciones según la hora del día, el día de la semana o la estación del año.

2) *Clasificación del Crimen:* La clasificación del crimen es un proceso fundamental para organizar y entender la diversidad de delitos en una ciudad. Los métodos de clasificación, como la clasificación supervisada y no supervisada, ayudan a agrupar incidentes similares y a analizar su distribución [18]. Estos enfoques son esenciales para la identificación precisa de patrones delictivos [19]. Los tipos de delitos se clasifican según el código penal en 3 tipos: delitos graves, delitos menores y violaciones. Nos enfocaremos en los delitos graves, estos son más serios, que generalmente conllevan penas de prisión prolongadas, multas significativas, o ambas. Ejemplos de delitos graves incluyen homicidio, secuestro, violación, robo a mano armada, y tráfico de drogas. Las consecuencias de ser condenado por un delito grave suelen ser severas, incluyendo largas penas de cárcel y, en algunos casos, la posibilidad de recibir una condena a cadena perpetua o pena de muerte, dependiendo de la jurisdicción.

3) *Hotspots Criminales:* Los hotspots criminales son áreas geográficas con una alta concentración de delitos. Estos se identifican utilizando técnicas como la densidad de kernel

y el análisis de puntos calientes [20]. La identificación de hotspots es una práctica clave en la criminología y en la implementación de estrategias de prevención del crimen [21], ya que permite a las fuerzas del orden concentrar sus recursos en áreas donde son más necesarios. Además, el análisis continuo de los hotspots permite a las fuerzas del orden adaptarse rápidamente a los cambios en los patrones delictivos, mejorando la efectividad de sus intervenciones al concentrar la vigilancia policial, mejorar la iluminación, aumentar la presencia de cámaras de seguridad, y fomentar la participación comunitaria en estas áreas, es posible reducir significativamente la incidencia delictiva.

#### C. Distribución geográfica - temporal

La comprensión de la distribución geográfica y temporal de los delitos es esencial para el análisis de patrones criminales [22]. Esta subsección explora cómo se distribuyen los delitos en diferentes áreas de la ciudad y cómo varían a lo largo del tiempo, proporcionando una base para predecir futuras tendencias delictivas [23].

1) *Distribución geográfica:* Estudia la distribución geográfica de los delitos en la ciudad de Nueva York y sus patrones, el conjunto de datos proporciona las coordenadas geográficas (latitud y longitud) de la escena del crimen. Utilizamos estas coordenadas para trazar un mapa de calor para descubrir los puntos calientes. Se analiza cómo los delitos se distribuyen espacialmente en la ciudad de Nueva York, utilizando mapas de calor y otras visualizaciones geoespaciales para mostrar las áreas con mayor y menor incidencia delictiva [24]. Se discuten posibles razones detrás de estas distribuciones [25] y se muestra altos niveles de delincuencia en los diferentes puntos.

2) *Distribución temporal:* Se examina la distribución de delitos a lo largo del tiempo, considerando factores como la estacionalidad, los ciclos diarios y semanales, y los eventos especiales [26]. Se analiza cómo ciertos delitos tienden a ocurrir en momentos específicos y cómo esta información puede utilizarse para prevenir futuros incidentes [27].

#### D. Toma de decisiones

La toma de decisiones es un proceso que implica elegir entre diferentes opciones para alcanzar un objetivo. En el contexto de la seguridad pública se beneficia enormemente del análisis de datos y la visualización de patrones [28]. Los resultados del análisis de patrones criminales informan y guían decisiones estratégicas de las autoridades, como la asignación de recursos policiales y la implementación de políticas de seguridad [29].

#### E. La plataforma de análisis geovisual basada en la web

Una plataforma interactiva para el análisis geovisual y visualización de patrones Espacio-Temporales, es una plataforma que integra datos espaciales y temporales para proporcionar una visualización interactiva de los patrones criminales en la ciudad de Nueva York [30]. Se detallan las características clave de la plataforma, incluyendo su interfaz de usuario, las tecnologías subyacentes (como Streamlit y PySpark), y su

capacidad para facilitar la toma de decisiones en tiempo real [31]. Se utilizó Streamlit para crear una interfaz interactiva y amigable para el usuario, PySpark para el procesamiento y análisis de grandes volúmenes de datos espacio-temporales, Dashboards personalizados para la visualización de datos y la interpretación de resultados y Hotspot para identificar y visualizar hotspots o zonas de alta incidencia delictiva.

#### IV. ANÁLISIS DE TAREAS

Después de realizar una revisión, identificamos nuestro objetivo como comprender la dinámica de los delitos graves en la ciudad de Nueva York mediante el análisis de la variación de los patrones delictivos en el espacio y el tiempo. A partir de los procesos iterativos, compilamos la siguiente lista de tareas de análisis significativas como se detalla a continuación:

- **Selecciones interactivas (T1):** ¿Cómo se pueden seleccionar de forma interactiva las características? ¿Es posible hacer que la selección interactiva sea lo suficientemente flexible?.

Los usuarios primero deben comprender los cambios temporales generales, incluido cuándo y qué tipo de cambios ocurren. Después de comprender esta información básica, los usuarios pueden descubrir patrones interesantes y explorar más a fondo.

- **Patrones delictivos en la ciudad (T2):** ¿Cuáles son los patrones delictivos?.

El sistema debe proporcionar información sobre las características geográficas de la evolución de los delitos graves en la ciudad de Nueva York, respaldando la percepción de la agregación de la distribución espacial y sus cambios a lo largo del tiempo.

- **Dinámica de los delitos a lo largo del tiempo (T3):** ¿Cómo han evolucionado los delitos, a lo largo del tiempo? Más específicamente, ¿han cambiado los patrones delictivos a lo largo de los años? ¿Son estacionales los tipos de delito?.

Detectar y explorar patrones de secuencia y las relaciones entre subsecuencias dentro de un período determinado. Se puede realizar análisis integrales basados en un rango de tiempo más amplio y analizar características locales (transiciones) basadas en cambios de corto plazo.

- **Patrones delictivos y puntos calientes en el espacio (T4):** ¿Cuáles son los puntos calientes en la ciudad? ¿Cuáles son sus patrones delictivos? ¿Qué tan diferentes (si existe la diferencia) son los patrones delictivos en distintos puntos calientes dentro la ciudad?.

- **Características de las víctimas y delincuentes a lo largo del tiempo (T5):** ¿Que características físicas tienen las víctimas y delincuentes a lo largo del tiempo en la ciudad? ¿Han cambiado los patrones delictivos según las características físicas de las víctimas y delincuentes?.

La falta de mecanismos interactivos para seleccionar regiones de interés combinadas con técnicas de análisis y visualización de propósito general han impedido que se explore libremente los datos para verificar hipótesis y conjjeturas.

Mientras que las tareas T4 y T5 están asociadas al problema de analizar puntos críticos. Para abordarse adecuadamente, esas tareas exigen mecanismos específicos para detectar puntos críticos y también recursos visuales para explorarlos y comprenderlos. Entre nuestros objetivos se encuentra la integración de métodos de selección interactivos y herramientas de análisis visual dedicadas para realizar un análisis tanto confirmatorio como exploratorio.

#### V. BASE DE DATOS

Este conjunto de datos incluye todos los delitos graves, delitos menores y violaciones válidos denunciados al Departamento de Policía de la ciudad de Nueva York (NYPD) hasta el año 2023.

NYC Open Data es administrado por el Equipo de Datos Abiertos de la Oficina de Tecnología e Innovación (OTI) de la Ciudad de Nueva York . El equipo trabaja con agencias de la ciudad para identificar y hacer que los datos estén disponibles, coordinar las operaciones y mejoras de la plataforma y promover el uso de datos abiertos tanto dentro del gobierno como en toda la ciudad de Nueva York. Cada agencia de la Ciudad también tiene un Coordinador de Datos Abiertos, que sirve como el principal punto de contacto para el equipo de Datos Abiertos y el público, y trabaja para identificar, documentar, estructurar y gestionar los conjuntos de datos públicos de la agencia.

En la tabla I se detalla cuales son datos que se presenta en nulos en la Base de Datos.

Columna	Cantidad	Porcentaje
TRANSIT_DISTRICT	8716793	97.778479
CMPLNT_TO_DT	1818958	20.403713
PD_CD	7593	0.085173
ADDR_PCT_CD	771	0.008649
CMPLNT_FR_DT	655	0.007347
Longitude	466	0.005227
Y_COORD_CD	466	0.005227
Latitude	466	0.005227
X_COORD_CD	466	0.005227
LOC_OF_OCCUR_DESC	234	0.002625

TABLE I: Valores Nulos

Por el análisis de datos nulos se realizó una limpieza de datos, donde se verificó que la información mas consolidada se encontraba dentro del rango de años 2018 al 2023.

Se identificó que en la Base de Datos hay 7 columnas de tipo float64, 2 de tipo int64 y 26 de tipo object. En la Tabla II se detalla el tipo de dato por columna.

Tipo	Columnas
object	CMPLNT_NUM, CMPLNT_FR_DT, CMPLNT_FR_TM, CMPLNT_TO_DT, CMPLNT_TO_TM, RPT_DT, OFNS_DESC, PD_DESC, CRM_ATPT_CPTD_CD, LAW_CAT_CD, BORO_NM, LOC_OF_OCCUR_DESC, PREM_TYP_DESC, JURIS_DESC, PARKS_NM, HADEVELOPT, HOUSING_PSA SUSP_AGE_GROUP SUSP_RACE SUSP_SEX Lat_Lon PATROL_BORO STATION_NAME VIC_AGE_GROUP VIC_RACE y VIC_SEX
float64	ADDR_PCT_CD, PD_CD, X_COORD_CD, Y_COORD_CD, TRANSIT_DISTRICT Latitude y Longitude
int64	KY_CD y JURISDICTION_CODE

TABLE II: Tipos de datos por Columna

## VI. PROPUESTA

En este trabajo, proponemos una canalización unificada que contiene 3 etapas como visualizamos en la Figura 2, es decir, definición de tareas (Sección IV), preprocesamiento de datos, análisis de datos, visualización de datos (Sección VII) y evaluación (Sección VIII y IX). Finalmente, implementamos una aplicación de análisis visual interactiva basada en la web.

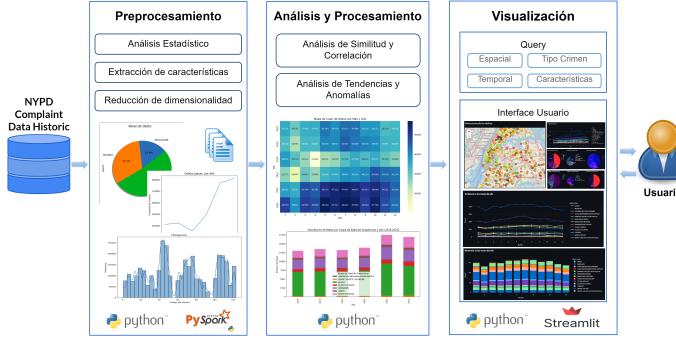


Fig. 1: Pipeline

Después de una serie de operaciones de preprocesamiento en los datos sin procesar, con base en las tareas de análisis anteriores, procesamos aún más los datos empleando métodos de coincidencia de patrones y agrupamiento, y construimos un prototipo de sistema de análisis visual. Finalmente, el sistema proporciona visualizaciones vinculadas e interacciones flexibles para guiar mejor al usuario en el análisis de la evolución los delitos graves denunciados al Departamento de Policía de la ciudad de Nueva York (NYPD) a lo largo del tiempo.

## VII. DISEÑO VISUAL

Esta sección se presenta el diseño visual, enfocándose en las tareas de análisis presentadas en la Sección IV. La tabla III muestra las propiedades de cada vista. Por ejemplo, la vista de mapa muestra la faceta espacial y la vista ranking de tipo las facetas temporales y de tipo de delito. Las columnas bajo la categoría de filtro muestran cómo interactuar con cada vista. Algunas vistas permiten restringir el espacio, el tiempo, los tipos de delito y características de las víctimas y delincuentes.

	Facet				Filter			
	Space	Time	Type	Feature	Space	Time	Type	Feature
Map View	✓				✓			
Hotspot View	✓							
Temporal View		✓				✓		
Cumulative Temporal View		✓		✓		✓	✓	
Ranking Type View		✓				✓	✓	
Victim Features View			✓					✓
Suspected Features View				✓				✓

TABLE III: Propiedades de la Vista

El diseño de los recursos visuales fue impulsado por las tareas analíticas descritas en la sección IV. En la tabla IV, las columnas bajo la categoría de tareas indican la relación de cada vista y las tareas analíticas.

	Tareas					
	T1	T2	T3	T4	T5	
Map View	✓				✓	✓
Hotspot View	✓				✓	✓
Temporal View	✓		✓		✓	
Cumulative Temporal View	✓		✓		✓	
Ranking Type View	✓					
Victim Features View	✓				✓	
Suspected Features View	✓		✓			✓

TABLE IV: Tareas analíticas

En el área de análisis de delitos, siempre se han utilizado visualizaciones para mostrar los datos; sin embargo, se necesitan mejoras o nuevos diseños sobre las visualizaciones existentes.

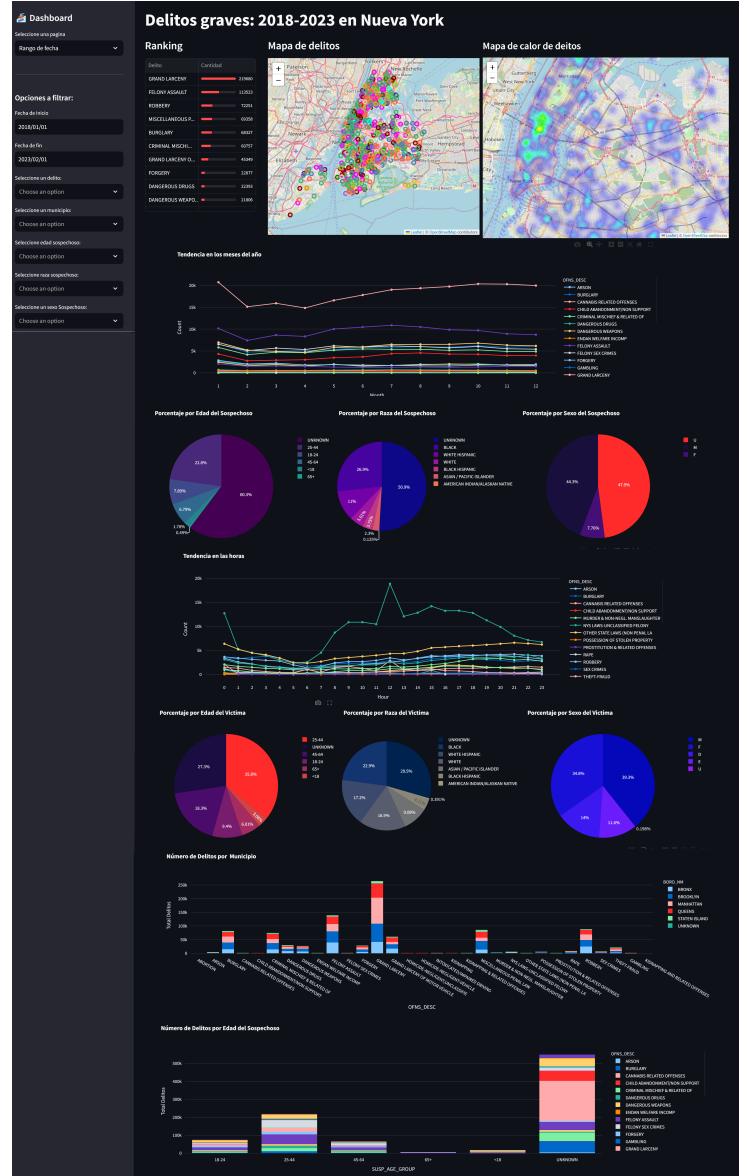


Fig. 2: Plataforma interactiva para el Análisis y Visualización de patrones Espacio-Temporales

A continuación, describimos cada componente visual, para un mayor el análisis de los delitos graves en la ciudad de Nueva York.

- **Map View:** Este es el primer componente utilizado por los usuarios para iniciar el proceso analítico, donde el usuario puede definir uno o varios municipios de interés. Esta vista se compone de un mapa geográfico y un mapa coroplético para codificar el número de delitos cometidos en cada sitio de la región. Además, los usuarios pueden hacer zoom y desplazarse por el mapa.
- **Hotspot View:** Un componente importante es la identificación de puntos críticos. En esta vista, utilizamos mapas para representar la distribución espacial de los puntos críticos. Con esta distribución de valores, damos más relevancia a los puntos calientes donde el número de delitos es mayor.
- **Temporal View:** Esta vista ofrece una descripción general de la cantidad de delitos cometidos durante todo el período de tiempo, basándose en un gráfico de líneas con un área rellena entre el valor de los datos y la línea base cero. En esta vista, podemos restringir el análisis a un intervalo de tiempo particular.
- **Cumulative Temporal View:** Esta vista utiliza un gráfico de barras para presentar la cantidad de delitos acumulados. En esta vista, podemos ver algunos patrones de intervalos de tiempo continuos. Esto también es muy útil para poder realizar una comparación adecuada entre .
- **Ranking Type View:** Esta vista utiliza un gráfico de barras para presentar la cantidad de delitos en un período de tiempo. Esto también es muy útil para comparar los delitos mas frecuentes.
- **Victim Features View:** En esta vista, utilizamos varios gráficos de barras con un diseño radial. Cada gráfico representa la edad, la raza y sexo del sospechoso. Cada gráfico está dividido en sectores, donde cada sector está compuesto por las características mas relevantes de la víctima.
- **Suspected Features View:** En esta vista, utilizamos varios gráficos de barras con un diseño radial. Cada gráfico representa la edad, la raza y sexo del sospechoso. Cada gráfico está dividido en sectores, donde cada sector está compuesto por las características mas relevantes del sospechoso.

### VIII. RESULTADOS

El análisis de delitos graves en la Ciudad de Nueva York desde 2018 hasta 2023 muestra un aumento general en la incidencia de crímenes. Entre 2018 y 2023, los delitos graves en la Ciudad de Nueva York aumentaron un 30%, pasando de 129,965 a 168,865 casos. Los robos crecieron de 12,965 a 16,865, mientras que los asaltos subieron de 20,402 a 27,630. El robo mayor aumentó de 43,545 a 47,919. Sin embargo, los crímenes sexuales disminuyeron de 1,408 a 900. Aunque los homicidios fluctuaron, hubo una tendencia general al alza, con el año 2022 marcando el mayor número de delitos graves con 174,431 casos, y 2023 mostrando una ligera disminución

pero aún cifras altas.

Brooklyn es el distrito con más delitos graves, con un incremento de 43,979 en 2018 a 50,282 en 2023. Manhattan y Queens también mostraron aumentos significativos, mientras que El Bronx experimentó un notable crecimiento, y Staten Island, aunque con cifras más bajas, también creció. En 2022 se reportó el mayor número de delitos graves con 174,431 incidentes, pero en 2023 hubo una ligera disminución a 168,865, manteniéndose aún por encima de los niveles anteriores.

### IX. DISCUSIÓN

El aumento en robos y asaltos podría relacionarse con factores socioeconómicos como el desempleo y las desigualdades, así como con el impacto residual de la pandemia. La disminución de crímenes sexuales podría deberse a mejoras en prevención y denuncia, aunque también podría reflejar una menor disposición de las víctimas a reportar estos delitos. Las variaciones anuales podrían estar influidas por cambios en políticas de seguridad pública y aplicación de la ley. Se recomienda investigar más a fondo estos factores socioeconómicos y demográficos, y utilizar datos cualitativos para entender mejor las dinámicas de la criminalidad.

La alta incidencia en Brooklyn y Manhattan puede reflejar su densidad poblacional, mientras que el notable incremento en el Bronx sugiere una necesidad de mejorar las políticas de prevención. Staten Island, con menor criminalidad, enfrenta menos desafíos. Las fluctuaciones en delitos con ubicación desconocida podrían señalar problemas en la recolección de datos.

### X. CONCLUSIONES

Entre 2018 y 2023, los delitos graves en Nueva York aumentaron un 30%. Los robos y asaltos crecieron, mientras que los crímenes sexuales disminuyeron. El robo mayor también subió significativamente. El año 2022 tuvo el mayor número de delitos graves, con una ligera disminución en 2023. Esto indica la necesidad de investigar las causas detrás de estas tendencias.

Brooklyn tiene la mayor cantidad de delitos, seguido por Manhattan y Queens. El Bronx también muestra un notable incremento, mientras que Staten Island, con cifras más bajas, también está en alza. La mayor cantidad de delitos se registró en 2022, con una ligera disminución en 2023.

### XI. TRABAJOS FUTUROS

Para mejorar la aplicación se está pensando en un futuro integrar con otros conjuntos de datos como socioeconómicos y demográficos para obtener una visión más completa.

También, implementar modelos predictivos con aprendizaje automático para anticipar tasas futuras de criminalidad y

evaluar políticas de prevención. Optimizar la plataforma para análisis en tiempo real.

Finalmente, se puede realizar un análisis a nivel de barrios y evaluar las políticas públicas recientes, esto ayudaría a identificar áreas problemáticas y medir la efectividad de nuevas leyes.

## REFERENCES

- [1] A. C. Robinson, U. Demšar, A. B. Moore, A. Buckley, B. Jiang, K. Field, M.-J. Kraak, S. P. Camboim, and C. R. Sluter, "Geospatial big data and cartography: research challenges and opportunities for making maps that matter," *International Journal of Cartography*, vol. 3, no. sup1, pp. 32–60, 2017.
- [2] S. A. Ajagbe, M. A. Oladipupo, and E. O. Balogun, "Crime belt monitoring via data visualization: a case study of folium," *International Journal of Information Security, Privacy and Digital Forensic*, vol. 4, no. 2, pp. 35–44, 2020.
- [3] G. García-Zanabria, M. M. Raimundo, J. Poco, M. B. Nery, C. T. Silva, S. Adorno, and L. G. Nonato, "Cripav: Street-level crime patterns analysis and visualization," *IEEE Transactions on Visualization and Computer Graphics*, vol. 28, no. 12, pp. 4000–4015, 2022.
- [4] H. Y. Lau, "Discovering spatio-temporal pattern of city crime – visual analysis on felony crime in new york," *Preprints*, January 2021.
- [5] U. M. Butt, S. Letchmunan, F. H. Hassan, M. Ali, A. Baqir, and H. H. R. Sherazi, "Spatio-temporal crime hotspot detection and prediction: a systematic literature review," *IEEE access*, vol. 8, pp. 166553–166574, 2020.
- [6] G. Μποτσαράκος, "Spatial-temporal crime prediction using deep learning," 2022.
- [7] X. Wu, A. Poorthuis, R. Zurita-Milla, and M.-J. Kraak, "An interactive web-based geovisual analytics platform for co-clustering spatio-temporal data," *Computers & geosciences*, vol. 137, p. 104420, 2020.
- [8] M. A. Kaif, S. Samaiya, R. A. Purnima, T. Sivasankar, A. Roy, and A. Poojitha, "Development of an interactive web-based geovisual analytics platform for analysing crime data," in *2023 IEEE Symposium on Wireless Technology & Applications (ISWTA)*, pp. 158–162, 2023.
- [9] A. N. Binti and Y. B. Wah, "Data visualization of violent crime hotspots in malaysia," in *Soft Computing in Data Science* (Y. B. Wah, M. A. Hj, and B. M. W, eds.), (Singapore), pp. 350–363, Springer Singapore, 2019.
- [10] C. Catlett, E. Cesario, D. Talia, and A. Vinci, "Spatio-temporal crime predictions in smart cities: A data-driven approach and experiments," *Pervasive and Mobile Computing*, vol. 53, pp. 62–74, 2019.
- [11] M. de Castro Neto, N. Marcel, S. Pedro, R. Sara, R. Teresa, and P. Marco, "A dashboard for security forces data visualization and storytelling," in *Information Systems for Industry 4.0* (R. Isabel, Q. Rui, S. Paulo, and O. Tiago, eds.), (Cham), pp. 47–62, Springer International Publishing, 2019.
- [12] J. W. Tukey, *Exploratory data analysis*. Addison-Wesley Publishing Company, 1977.
- [13] J. T. Behrens, "Exploratory data analysis," *Review of research in education*, vol. 19, pp. 47–90, 1997.
- [14] J. E. Eck and R. V. Clarke, "Examining the role of crime facilitators in victimization: The case of ambush crime in st. louis," *Security Journal*, vol. 18, no. 2, pp. 7–15, 2005.
- [15] S. Wang and D. E. Brown, "Crime hotspot mapping using spatial and temporal kde (st-kde)," *Crime Science*, vol. 6, no. 1, pp. 1–19, 2017.
- [16] S. D. Johnson, K. J. Bowers, and K. Pease, "Near repeats: A cross cultural analysis of crime patterns," *European Journal of Criminology*, vol. 5, no. 1, pp. 89–105, 2008.
- [17] P. J. Brantingham and P. L. Brantingham, *Patterns in crime*. Macmillan Publishing Company, 1984.
- [18] K. E. Chan and R. F. Meier, "Classifying data from the national crime victimization survey: Examining victimization over time," *Journal of Quantitative Criminology*, vol. 21, no. 2, pp. 199–217, 2005.
- [19] B. J. Reich and B. P. Carlin, "Classification of crimes in a heterogeneous population: A mixture model approach," *Journal of the American Statistical Association*, vol. 98, no. 462, pp. 611–621, 2003.
- [20] J. E. Eck, S. Chainey, J. G. Cameron, M. Leitner, and R. E. Wilson, "Mapping crime: Understanding hotspots," 2005.
- [21] C. Weinborn, S. D. Johnson, S. N. Baharom, N. Bouhana, and K. J. Bowers, "Crime, space, and networks: Exploring the spatial and network characteristics of place-based street robbery," *Journal of Quantitative Criminology*, vol. 33, no. 1, pp. 91–119, 2017.
- [22] J. H. Ratcliffe, *The geography of crime mapping: Using GIS in criminology and criminal justice*. CRC Press, 2010.
- [23] M. A. Andresen, "Spatial heterogeneity in crime analysis," *Crime Mapping*, vol. 6, no. 1, pp. 1–27, 2014.
- [24] B. Brown and W. Bernasco, "Hot spots of crime: A systematic review of the literature," *Crime and Delinquency*, vol. 62, no. 4, pp. 491–514, 2016.
- [25] R. P. Curiel and S. R. Bishop, "Geographical profiling of burglars in an urban area," *Journal of Quantitative Criminology*, vol. 33, no. 4, pp. 749–770, 2017.
- [26] M. Felson and L. E. Cohen, "Routine activity theory," *Criminology theory: Past to present: Essential readings*, vol. 3, pp. 174–184, 2006.
- [27] G. Rosser, T. Davies, K. J. Bowers, S. D. Johnson, and T. Cheng, "Predicting crime using spatial and temporal bayesian methods," *PloS one*, vol. 12, no. 1, p. e0169733, 2017.
- [28] W. L. Gorr, A. M. Olligschlaeger, and Y. Thompson, "Early warning system for crime patterns: A proposal," *Criminology and Public Policy*, vol. 2, no. 2, pp. 187–204, 1998.
- [29] K. J. Bowers and S. D. Johnson, "Anticipating crime: Using a genetic algorithm to model criminal behaviour," *Evolutionary Computation*, vol. 12, no. 3, pp. 369–402, 2004.
- [30] A. Y. Grinberger and A. S. Fotheringham, "Crime mapping: Toward the design of a geovisualization portal," *Geographic Information Science and Technology*, vol. 29, no. 4, pp. 282–299, 2018.
- [31] J. Dong, H. J. Song, L. Jia, and K. S. Tan, "Interactive web-based crime mapping," *Journal of Computing in Civil Engineering*, vol. 33, no. 6, p. 04019039, 2019.